

CLASIFICACIÓN DE IMÁGENES NATURALES CON CNNs

Comparación entre arquitecturas clásicas, profundas y *transfer learning*

Andrés Molina, David Duque, Yurladys Cross y Emilio Henao


Descripción del problema

Se realiza aprendizaje supervisado de clasificación multiclase sobre imágenes naturales. El objetivo es asignar a cada imagen una de seis categorías de paisajes y evaluar cómo distintas arquitecturas de redes neuronales convolucionales se comparan entre sí, contrastando modelos clásicos, modelos profundos entrenados desde cero y un enfoque de *transfer learning*.

Metodología

Se entrenaron y evaluaron cuatro arquitecturas de CNN bajo un protocolo idéntico para garantizar comparabilidad. La métrica de selección fue la *validation loss* con *Early Stopping* (*patience*=5):

- LeNet5 (adaptada), VGGMini y ResNet18 entrenadas desde cero.
- ResNet18 preentrenada en ImageNet con *fine-tuning* y *learning rates* diferenciales: $1e-4$ *backbone* / $1e-3$ *head*.




Ejemplos representativos de las seis clases de la base de datos.

Base de datos

Intel Image Classification (Kaggle, Puneet6060): Aprox. 25.000 imágenes RGB de 150×150 px etiquetadas en seis clases (*buildings*, *forest*, *glaciers*, *mountains*, *sea*, *street*). Características técnicas y preprocesamiento:

- A. Partición: Aprox. 14.000 imágenes de entrenamiento y 3.000 de prueba.
- B. Imágenes redimensionadas a 150×150 px y normalizadas a tensores en [0,1].
- C. Reto: clases que se pueden confundir (*glacier* vs. *mountain*; *buildings* vs. *streets*).




Distribución de clases por conjunto de entrenamiento y prueba

Resultados

ResNet18 preentrenada alcanzó el mejor desempeño global, superando en 6,6 p.p. al mejor modelo entrenado desde cero. F1-score por clase.


	LeNet5	VGGMini	ResNet18	ResNet18 PT
Accuracy	0.829	0.850	0.860	0.926
buildings	0.795	0.813	0.848	0.929
forest	0.948	0.957	0.961	0.985
glacier	0.802	0.802	0.808	0.884
mountain	0.785	0.807	0.809	0.887
sea	0.816	0.868	0.867	0.948
street	0.838	0.860	0.880	0.927
macro avg	0.831	0.851	0.862	0.927

Accuracy y F1-score por clase.



Comparación de Accuracy entre modelos.


Las confusiones principales son *glacier-mountain* (93 casos cruzados) y *street-buildings* (58 casos), reflejando similitudes visuales reales de la base de datos.



Matriz de confusión ResNet18 Pretrained-

Conclusiones

- **Transfer learning** supera ampliamente: ResNet18_Pretrain logró 92.57% de *accuracy* y 0.220 de *loss*, superando en 6.6 p.p. al mejor modelo entrenado desde cero.
- **Profundidad es diferente a desempeño:** ResNet18 desde cero superó marginalmente a VGGMini (+0.9 p.p.). Con aprox. 14k imágenes la profundidad no se aprovecha sin pesos preentrenados.
- **Confusiones del dataset:** los pares *glacier-mountain* y *buildings-street* son el cuello de botella; un *data augmentation* más específica podría mitigarlas.



Accuracy train – validation: ResNet18 Pretrained

Referencias

1. Bansal, P. Intel Image Classification. Kaggle (2018).